Report *Data Reduction, Information Design e Data Visualization*

Jody Zojzi

Matricola 191317

INTRODUZIONE E DESCRIZIONE DEL DATASET

Il dataset "Emilia-Romagna Circular Economy" contiene 329 osservazioni relative ai comuni della regione e comprende un insieme di variabili eterogenee che descrivono il territorio sotto il profilo ambientale, demografico, tecnologico ed economico.

Il lavoro è impostato come una ricerca del modello statistico più adatto a spiegare la percentuale di raccolta differenziata a livello comunale. L'attenzione è rivolta in particolare alla capacità esplicativa del modello, con l'obiettivo di individuare quali fattori socio-economici, territoriali e infrastrutturali contribuiscano a spiegare le differenze osservate tra i comuni.

La variabile di interesse per l'analisi è la **Raccolta Differenziata 2022**, espressa in percentuale, che rappresenta il livello di performance ambientale raggiunto da ciascun comune.

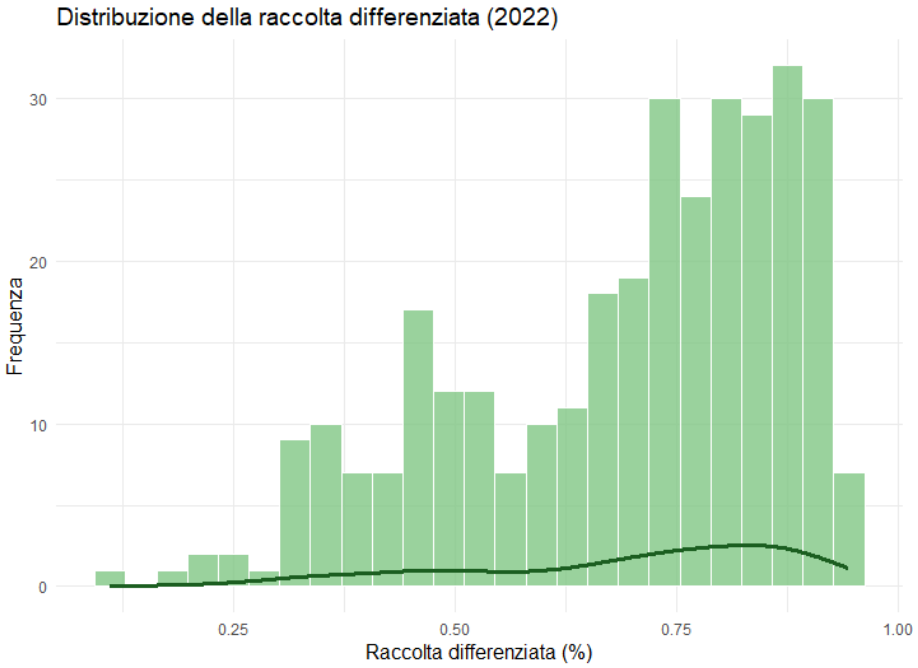

Il grafico mostra una raccolta differenziata mediamente elevata, ma con un'elevata variabilità tra i comuni. La coesistenza di valori molto alti e molto bassi indica che il fenomeno non può essere spiegato da un unico livello medio regionale, ma è influenzato da fattori territoriali, infrastrutturali e socio-economici.

La distribuzione della raccolta differenziata risulta fortemente variabile tra i comuni. Se si osservano esclusivamente le medie provinciali *(grafico a destra*), emergono risultati come Modena mediamente più performante rispetto a Parma e Bologna.

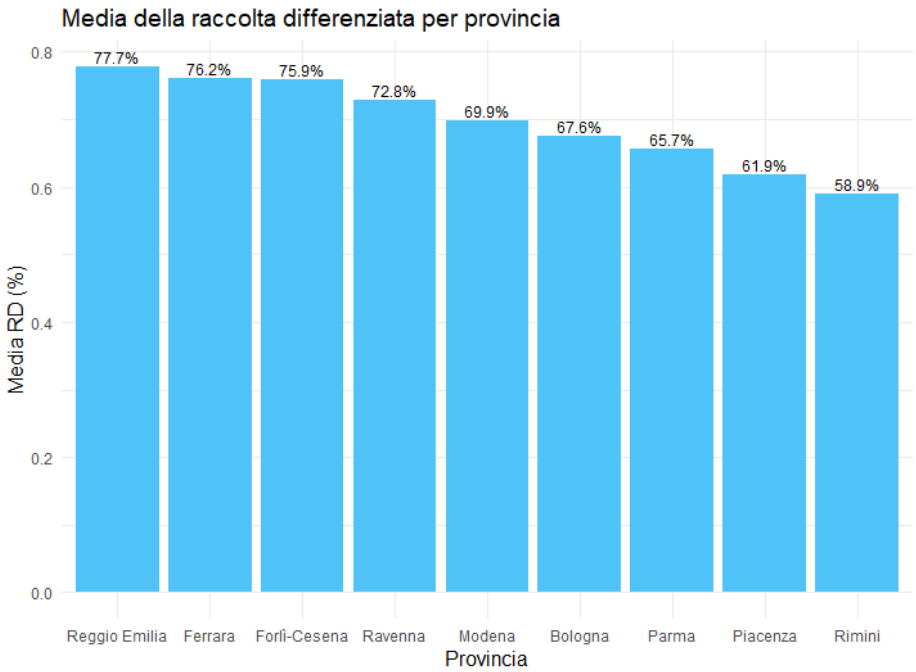

Tuttavia, l'analisi delle distribuzioni tramite boxplot *(grafico in basso*) mostra un quadro differente: le mediane di Parma e Bologna risultano più elevate, indicando una performance dei comuni superiore rispetto a quella di Modena. Questo confronto evidenzia come l'utilizzo delle sole medie provinciali possa fornire una rappresentazione parziale del fenomeno, mentre l'analisi dell'intera distribuzione consente una lettura più informativa delle differenze territoriali.

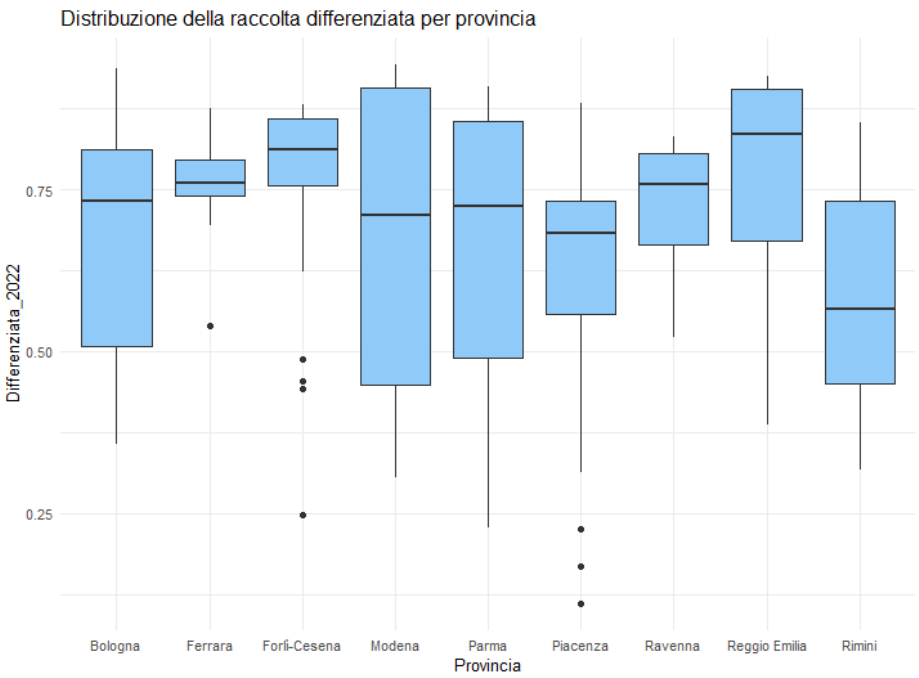

Per facilitare una lettura sistematica del dataset, le variabili sono state organizzate in quattro macro-aree tematiche:

• **Area demografica e sociale**: include indicatori quali il numero di auto per abitante e la classificazione dei comuni per dimensione. Queste variabili descrivono il grado di urbanizzazione e la struttura insediativa del territorio.

• **Area territoriale e ambientale**: comprende variabili relative alla superficie forestale, protetta e agricola, che descrivono la morfologia fisica dei comuni e ne distinguono la vocazione territoriale tra pianura, collina e Appennino.

• **Area infrastrutturale e tecnologica**: rappresentata principalmente dall'indicatore di digital divide, misura il livello di diffusione dei servizi digitali e sintetizza il divario tecnologico tra aree urbane e zone periferiche.

• **Area economico-produttiva**: riguarda la struttura economica dei comuni, includendo il numero di imprese e la presenza di attività agricole e turistiche, ed è caratterizzata da una marcata eterogeneità e da distribuzioni spesso asimmetriche.

```
> summary(dati_num2)
   CO2eq_2016        Auto1000ab_2016 Differenziata_2022 Stazioni ferroviarie_2021 Impresecertificate_2016 Popolazione_2011 Digitaldivide_2011
 Min.   :-141.123   Min.   :519.0   Min.   :0.1105     Min.   : 0.0000           Min.   : 0.0000         Min.   :    92   Min.   :  0.00
 1st Qu.:   3.408   1st Qu.:632.0   1st Qu.:0.5566     1st Qu.: 0.0000           1st Qu.: 0.0000         1st Qu.:  3059   1st Qu.:  4.00
 Median :  41.478   Median :654.5   Median :0.7427     Median : 0.0000           Median : 0.0000         Median :  6257   Median : 12.00
 Mean   : 112.629   Mean   :657.0   Mean   :0.6909     Mean   : 0.5061           Mean   : 0.4665         Mean   : 13219   Mean   : 25.61
 3rd Qu.:  84.815   3rd Qu.:682.0   3rd Qu.:0.8444     3rd Qu.: 1.0000           3rd Qu.: 0.0000         3rd Qu.: 11016   3rd Qu.: 35.25
 Max.   :4131.208   Max.   :808.0   Max.   :0.9443     Max.   :10.0000           Max.   :13.0000         Max.   :371337   Max.   :100.00
  Reddito_2020   Spesacomunale_2017  Partecipazelettorale_2022 Supforestale_2020 Numeroimprese_2021 Superficieagricola_2022 Impreseagricole_2010
 Min.   : 7150   Min.   :   341016   Min.   :54.40             Min.   :0.00000   Min.   :    7.0    Min.   :   24.32        Min.   :   2.0
 1st Qu.:14417   1st Qu.:  3811439   1st Qu.:68.94             1st Qu.:0.02327   1st Qu.:  224.5    1st Qu.: 1910.54        1st Qu.: 102.8
 Median :15551   Median :  6694018   Median :71.08             Median :0.09958   Median :  451.0    Median : 2956.89        Median : 151.5
 Mean   :15559   Mean   : 17552518   Mean   :70.73             Mean   :0.24936   Mean   : 1229.8    Mean   : 4059.51        Mean   : 223.1
 3rd Qu.:16531   3rd Qu.: 12247492   3rd Qu.:72.90             3rd Qu.:0.46639   3rd Qu.:  896.8    3rd Qu.: 4211.60        3rd Qu.: 243.0
 Max.   :22582   Max.   :681474037   Max.   :79.26             Max.   :0.89970   Max.   :44668.0    Max.   :45874.67        Max.   :2459.0
```

Dopo le operazioni di pulizia del dataset, che hanno incluso la rimozione delle osservazioni con valori mancanti e l'esclusione delle variabili affette da forte collinearità o da problematiche di natura temporale, vengono presentate le statistiche descrittive delle variabili selezionate. Tali variabili costituiscono l'insieme dei regressori utilizzati nella successiva fase di modellistica.

MODELLISTICA E ANALISI

La modellistica si è articolata in due fasi principali:

1. Scelta del modello
Sono stati confrontati modelli di regressione lineare usando diverse procedure di selezione delle variabili (best subset, forward e backward) per scegliere il modello con maggior capacità esplicativa.

2. Metodi di resampling
La validità dei modelli è stata valutata mediante tecniche di resampling, in particolare cross-validation (LOOCV) e bootstrap, al fine di verificarne stabilità, capacità predittiva e robustezza dei risultati.

CREAZIONE MODELLI E USO DI ALGORITMI PER SCELTA DELLE VARIABILI

Come primo passo esplorativo è stata costruita una matrice di correlazione per valutare le relazioni dirette tra le variabili e la raccolta differenziata (2022). Emergono correlazioni positive soprattutto con la partecipazione elettorale e il reddito, mentre risultano negative quelle con la superficie forestale, il digital divide e il numero di auto per abitante.

Questa analisi fornisce una prima indicazione dei fattori potenzialmente associati al fenomeno, che verranno approfonditi nella successiva fase di modellistica.

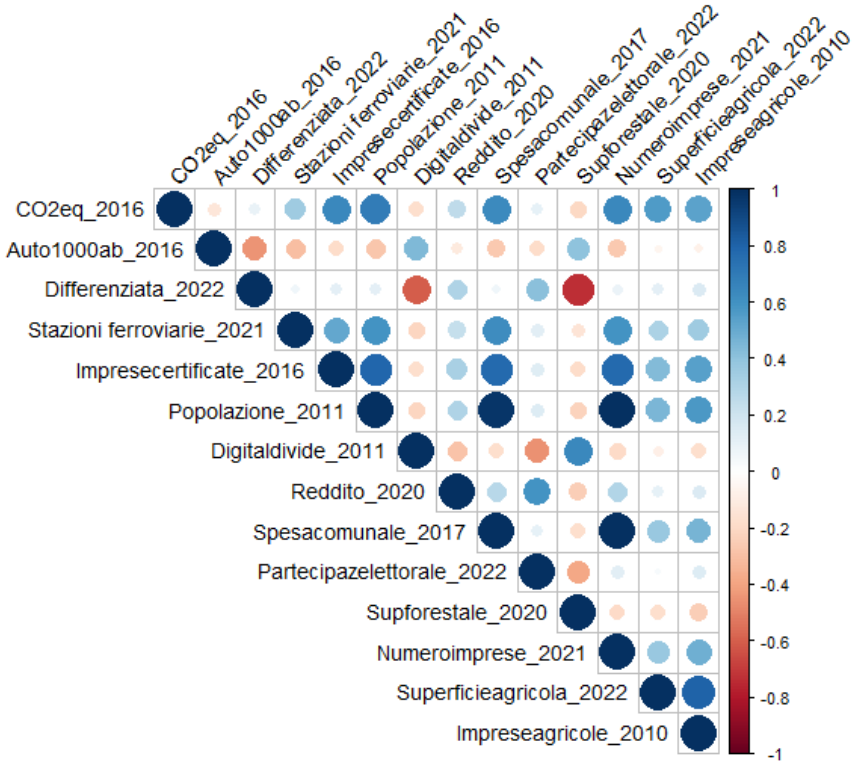

MODELLO LINEARE (con tutte le variabili dentro).

Subito è stato stimato un modello di regressione lineare includendo tutte le variabili disponibili, con l'obiettivo di osservare il comportamento del modello completo e individuare quali regressori emergano immediatamente come rilevanti.

Le variabili che risultano maggiormente associate alla raccolta differenziata sono il numero di **auto per abitante**, il **digital divide** e la **superficie forestale**, indicando un forte legame con fattori di struttura territoriale e fragilità infrastrutturale.

A partire da questo risultato, e per facilitarne la rappresentazione grafica, è stata successivamente introdotta una variabile dicotomica che distingue i comuni caratterizzati da un elevato livello di digital divide.

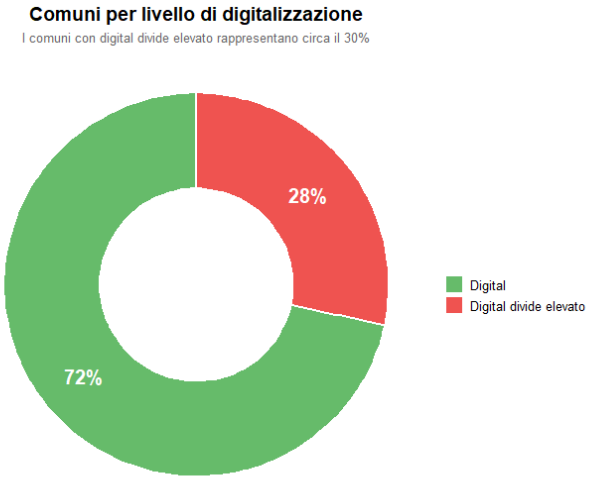

Il grafico sottostante evidenzia come i comuni con elevato digital divide tendano a registrare livelli più bassi di raccolta differenziata. L'associazione tra alta superficie forestale e maggiore motorizzazione suggerisce contesti rurali e dispersi, in cui la gestione della raccolta risulta più complessa.

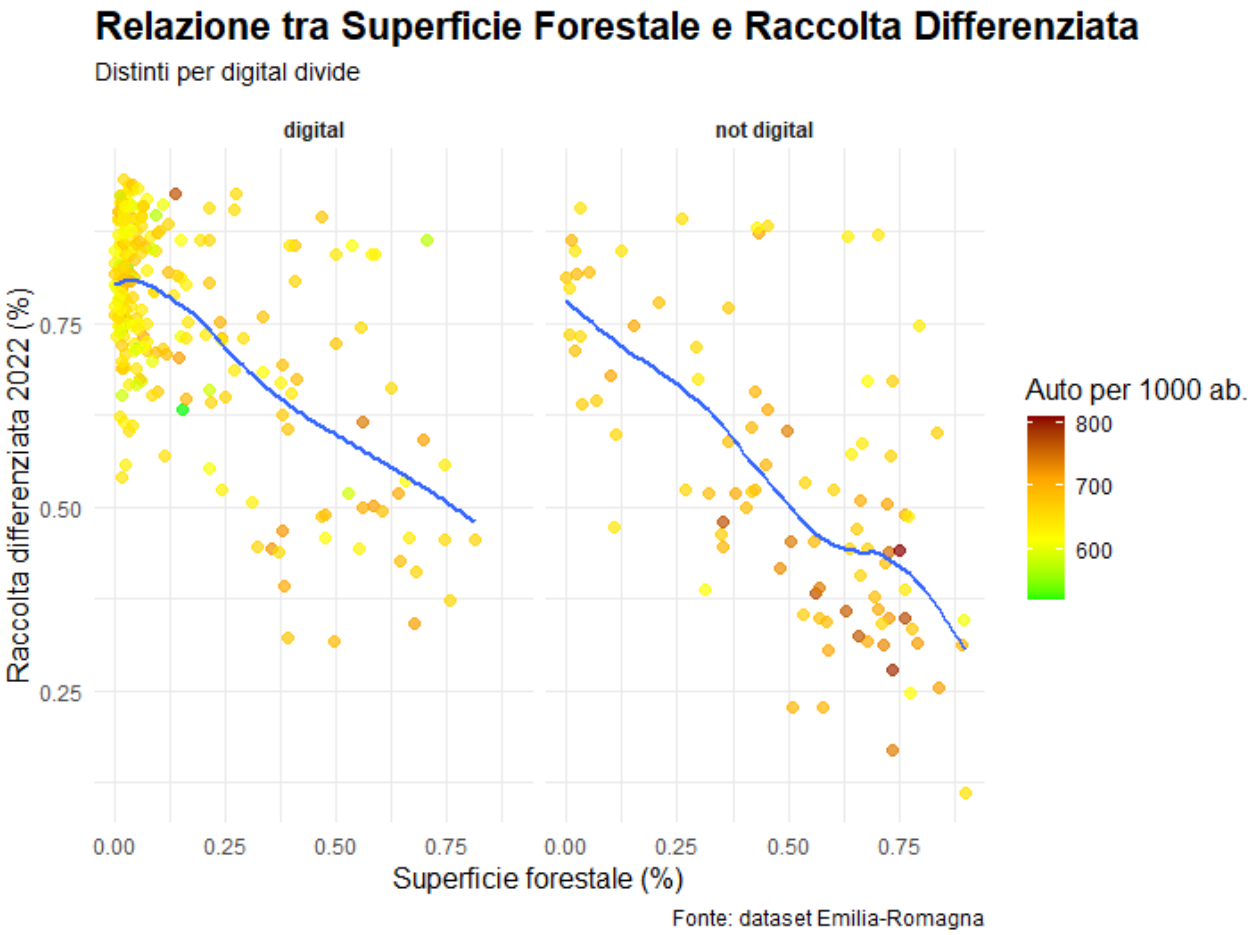

BEST SUBSET, FORWARD E BACKWARD.

Per individuare un modello efficiente, l'analisi è partita dall'applicazione dell'algoritmo di **best subset selection**, con l'obiettivo di esplorare sistematicamente tutte le possibili combinazioni di regressori.

A partire dai risultati del best subset, la scelta del modello è stata guidata da due approcci complementari, illustrati nei grafici sottostanti:

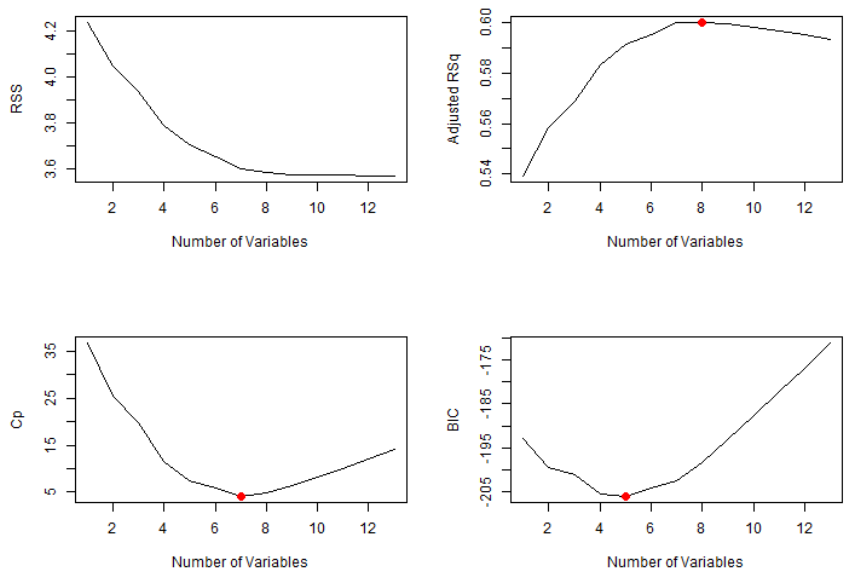

(i) la massimizzazione dell'**Adjusted R^2**, orientata a privilegiare la capacità esplicativa del modello;
(ii) la minimizzazione del **BIC**, criterio più severo e orientato alla selezione di modelli più parsimoniosi

I due approcci di selezione portano a modelli di dimensione diversa: l'approccio basato sull'Adjusted R^2 individua un modello con un numero maggiore di variabili, mentre il criterio BIC seleziona un modello più parsimonioso.

Tuttavia, le **variabili significative** che emergono come rilevanti risultano in larga parte coincidenti:

- **Approccio basato sull'Adjusted R^2: numero di auto per abitante, digital divide, reddito e superficie forestale.**

```
Coefficients:
                            Estimate Std. Error t value Pr(>|t|)
(Intercept)                1.172e+00  1.450e-01   8.083 2.62e-14 ***
CO2eq_2016                -3.978e-05  2.943e-05  -1.352  0.17766
Auto1000ab_2016           -8.411e-04  2.111e-04  -3.984 8.86e-05 ***
`Stazioni ferroviarie_2021` -1.913e-02  9.622e-03  -1.988  0.04786 *
Digitaldivide_2011        -9.401e-04  3.328e-04  -2.825  0.00511 **
Reddito_2020               1.237e-05  3.912e-06   3.161  0.00177 **
Spesacomunale_2017        -2.359e-10  2.190e-10  -1.077  0.28240
Supforestale_2020         -3.905e-01  3.755e-02 -10.398  < 2e-16 ***
Superficieagricola_2022    5.112e-06  2.272e-06   2.250  0.02533 *
---
```

- **Approccio basato sul BIC: numero di auto per abitante, digital divide, reddito, superficie forestale e numero di stazioni ferroviarie.**

```
Coefficients:
                            Estimate Std. Error t value Pr(>|t|)
(Intercept)                1.186e+00  1.463e-01   8.105 2.18e-14 ***
Supforestale_2020         -3.953e-01  3.733e-02 -10.587  < 2e-16 ***
`Stazioni ferroviarie_2021` -2.643e-02  7.758e-03  -3.407 0.000763 ***
Reddito_2020               1.053e-05  3.851e-06   2.735 0.006683 **
Digitaldivide_2011        -8.976e-04  3.342e-04  -2.686 0.007698 **
Auto1000ab_2016           -7.952e-04  2.123e-04  -3.745 0.000223 ***
```

Poiché forward e backward selezionano le **stesse variabili** della best subset selection, nelle analisi successive si farà riferimento unicamente ai modelli best subset. I risultati vengono quindi sintetizzati in una tabella riassuntiva.

~Modello,	~R2,	~Adj_R2,	~MSE,	~AIC,	~BIC,
"Tutte le variabili",	0.6137,	0.5935,	0.01087973,	-352.1563,	-298.6311,
"Best subset (Adj-R²)",	0.6124,	0.6002,	0.01107656,	-361.2610,	-325.5776,
"Best subset (BIC)",	0.5991,	0.5913,	0.01068958,	-358.4432,	-333.4648

Il modello selezionato tramite **best subset sulla base dell'Adjusted R^2** è quello che presenta la maggiore capacità esplicativa. In questo caso, le variabili che risultano maggiormente associate alla raccolta differenziata sono il numero di auto per abitante, il digital divide, il reddito e la superficie forestale.

Il modello selezionato tramite **best subset secondo il criterio BIC** risulta invece quello con le migliori prestazioni predittive.

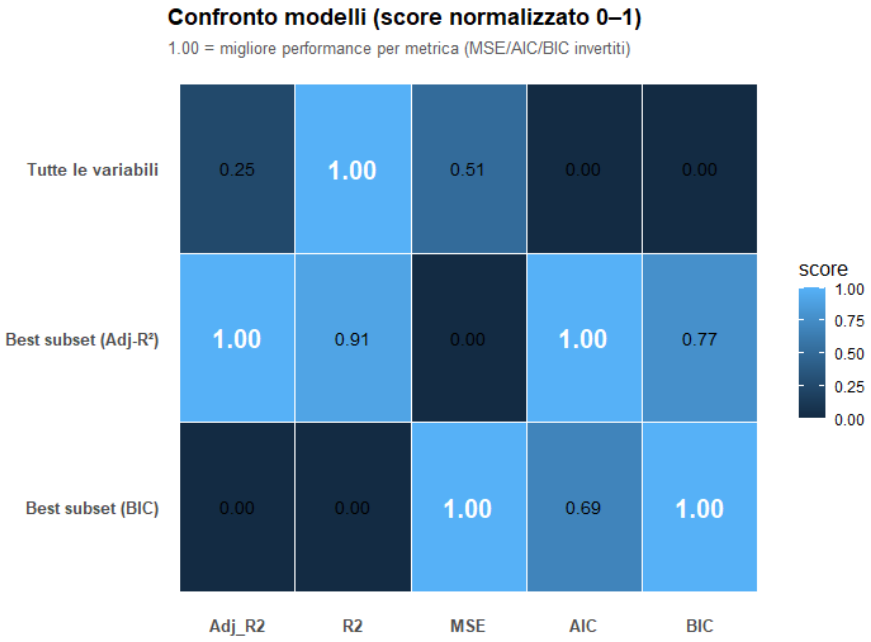

RICERCA - GOOGLE SCHOLAR

A supporto dei risultati ottenuti, è stata inoltre condotta una ricerca della letteratura e di studi applicativi disponibili online, al fine di verificare la coerenza delle evidenze emerse con quanto riportato da analisi e contributi di esperti nel settore. Di seguito sono riportati gli hyperlink ai lavori individuati, che confermano come fattori quali il digital divide, la ruralità del territorio e la complessità logistica incidano in modo significativo sulle performance di raccolta differenziata:

BIBLIOGRAFIA

[1] - **Internet use and higher farmer participation in domestic waste sorting: micro-survey data from 2126 farming households in rural China**

[2] - The Role of Internet and Social Interactions in Advancing Waste Sorting Behaviors in Rural Communities

[3] - Evolutionary process of household waste separation behavior based on social networks

[4] - Role of Waste Collection Efficiency in Providing a Cleaner Rural Environment

[5] - Optimisation of the economic, environmental and administrative efficiency of the municipal waste management model in rural areas

[6] - Raccolta dei rifiuti nelle comunità rurali: le sfide della normativa UE. Uno studio di caso nella contea di Neamț, Romania

[7] - Raccolta differenziata nei comuni montani. Un caso studio in Campania

2

METODI DI RESAMPLING

Il modello scelto per i controlli è il best subset sulla base dell'Adjusted R^2, in quanto registra il maggior valore di Adjusted R^2 e risponde quindi alla domanda **"chi spiega meglio"**.
Dopo la selezione del modello, l'analisi è stata completata mediante tecniche di ricampionamento al fine di valutarne la capacità di generalizzazione e la stabilità dei risultati. In particolare, sono state utilizzate la **Leave-One-Out Cross-Validation (LOOCV)** e il **bootstrap**.

La LOOCV fornisce una stima dell'errore predittivo più severa rispetto all'MSE osservato sul test set: l'aumento risulta contenuto, indicando che il modello mantiene una buona stabilità e non mostra segnali evidenti di overfitting.
Il bootstrap è stato invece utilizzato come controllo della stabilità dei coefficienti: attraverso ricampionamenti ripetuti del training set, si ottiene una distribuzione empirica delle stime dei coefficienti e dei relativi intervalli di confidenza. In questo modo è possibile verificare se i coefficienti mantengano segno e ordine di grandezza in modo consistente e se l'effetto di una variabile risulti robusto (ad esempio quando l'intervallo di confidenza non include lo zero), rafforzando l'interpretazione dei risultati del modello.

Successivamente, la stabilità dei coefficienti è stata analizzata tramite bootstrap, costruendo intervalli di confidenza al 95% e valutando l'inclusione o meno dello zero come criterio di robustezza degli effetti stimati. La costruzione degli IC è stata proposta dopo la lettura del seguente paper :

[8] - **Impact of internet use on pro-environmental behaviour mediated by environmental concern**

Nel *grafico sottostante* si osserva che le nostre variabili individuate come rilevanti nel modello risultano pienamente confermate in termini di robustezza, rafforzando l'affidabilità complessiva dei risultati ottenuti.

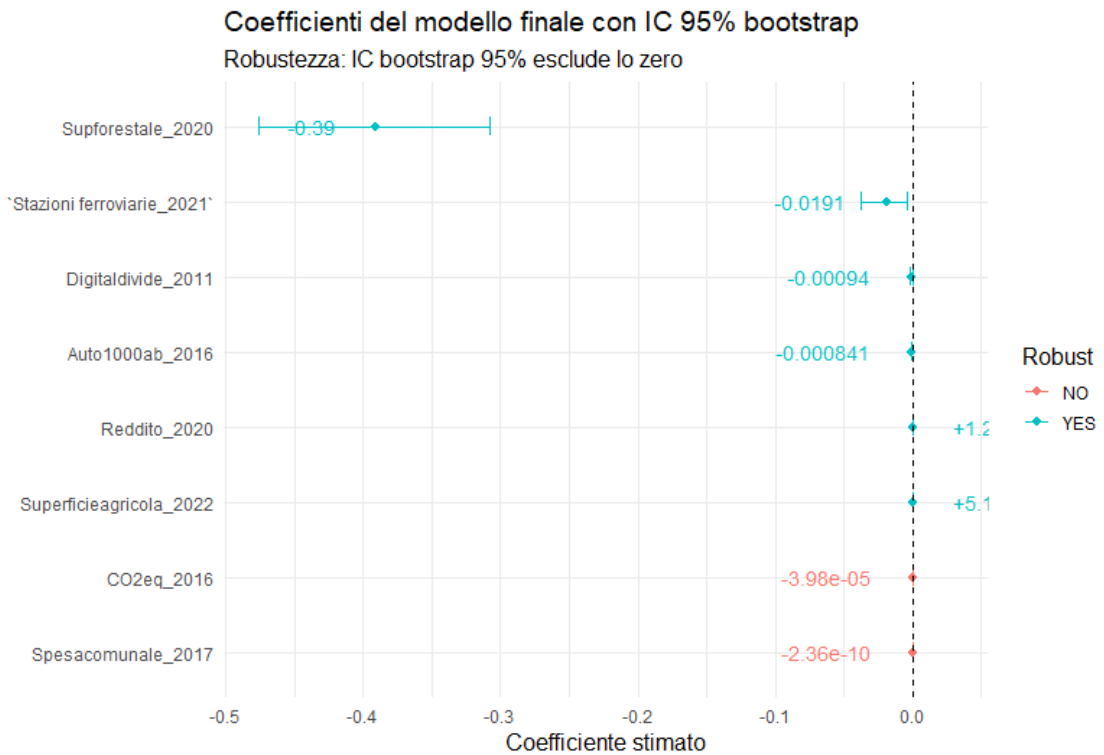

Come visto in precedenza, per l'obiettivo principale interpretativo è stato adottato il modello selezionato tramite **Adjusted_R**2**, perché massimizza la capacità esplicativa.
Come estensione ("tema bonus") orientata alla **predizione**, è stato poi considerato anche il modello selezionato tramite **BIC**, risultato più parsimonioso e con **MSE test** più basso.

A partire da questo modello BIC sono state provate alcune estensioni **non lineari** introducendo termini polinomiali di secondo grado su variabili chiave. Il confronto tra specificazioni è stato valutato tramite **LOOCV**, per distinguere tra miglioramenti osservati sul test set e miglioramenti realmente robusti.

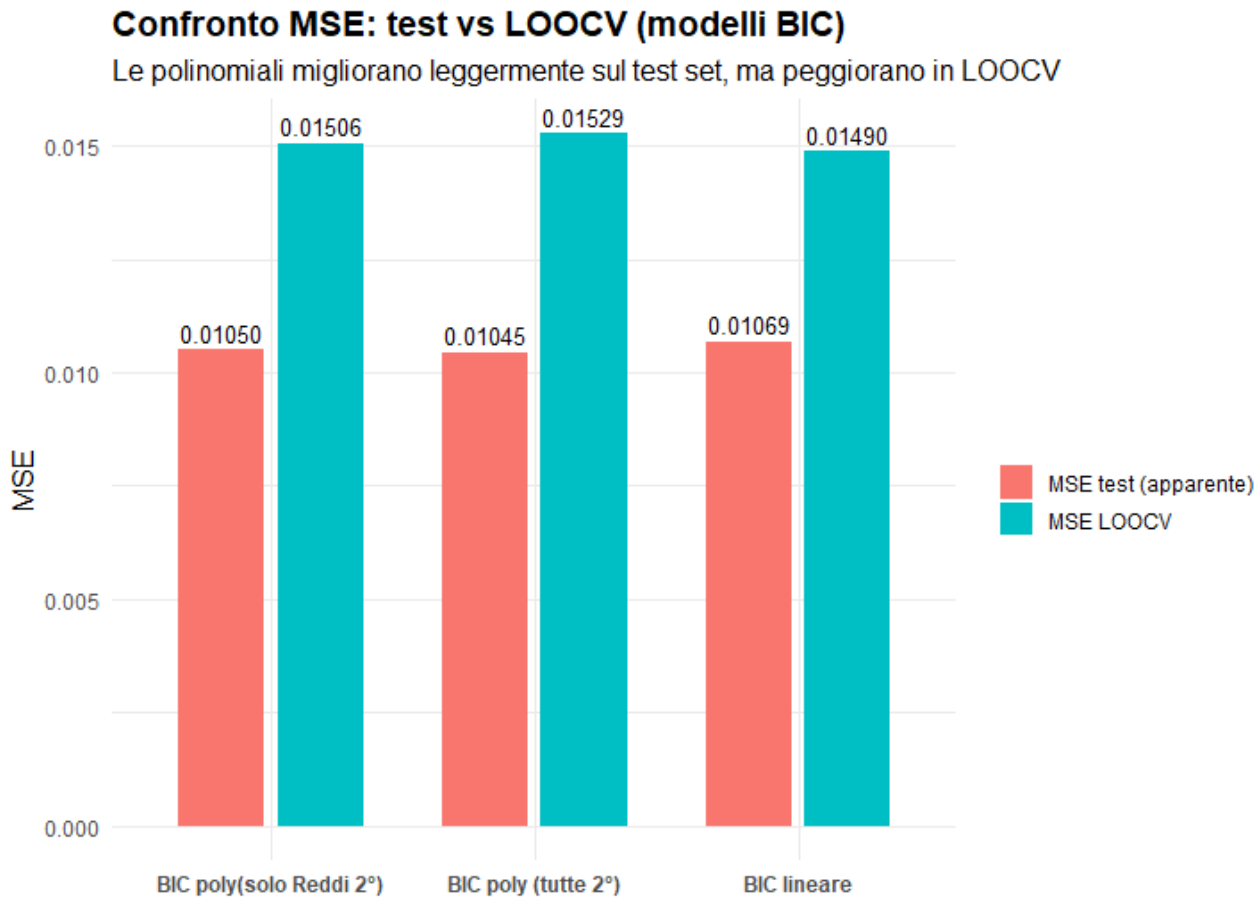

I risultati indicano che, nonostante un lieve miglioramento sul test per alcune polinomiali, la LOOCV peggiora: i modelli più complessi generalizzano meno. Di conseguenza, nell'estensione predittiva si mantiene come riferimento il modello BIC lineare, mentre il modello Adj-R^2 resta il riferimento principale per l'interpretazione.

CONCLUSIONI E SVILUPPI FUTURI

L'analisi ha individuato un insieme di fattori strutturali stabilmente associati alle differenze nei livelli di raccolta differenziata tra i comuni. La natura di tali fattori suggerisce però che il fenomeno non possa essere ricondotto a un'unica dimensione, ma vada interpretato come il risultato dell'interazione tra caratteristiche territoriali, infrastrutturali, socio-economiche e organizzative.

Miglioramenti dei dati:
Alla luce di ciò, un primo ambito di miglioramento della ricerca riguarda l'arricchimento del patrimonio informativo. In particolare, sarebbe utile integrare dati più dettagliati sull'organizzazione del servizio di raccolta (modalità operative, frequenze, estensione del porta-a-porta, presenza di centri di raccolta), indicatori di accessibilità e logistica, nonché informazioni più aggiornate e granulari sulla digitalizzazione dei servizi comunali e sull'interazione tra cittadini e amministrazioni. Inoltre, l'introduzione di una dimensione **temporale** (serie storiche o dati annuali) consentirebbe di distinguere differenze strutturali da variazioni dovute a cambiamenti di policy, investimenti o riorganizzazioni del servizio.

Sviluppi futuri delle analisi:
Come naturale prosecuzione, un possibile sviluppo futuro potrebbe consistere nell'applicazione di tecniche di clustering basate esclusivamente sulle variabili strutturali individuate come rilevanti (ad esempio digital divide, indicatori di ruralità/dispersione territoriale, superficie forestale), escludendo intenzionalmente la raccolta differenziata. In questo modo i cluster rappresenterebbero "tipologie di contesto" omogenee, indipendenti dalla performance ambientale osservata.
Una volta definiti i gruppi, sarebbe possibile analizzare i livelli di raccolta differenziata all'interno di ciascun cluster, distinguendo i casi in cui valori bassi risultano coerenti con vincoli strutturali (ruralità, dispersione territoriale, fragilità digitale o logistica) da situazioni in cui la bassa performance non trova una giustificazione evidente nel profilo del comune. Questo approccio permetterebbe anche di evidenziare eventuali "casi anomali", ossia comuni con performance bassa pur appartenendo a cluster strutturalmente favorevoli, su cui ipotizzare margini di miglioramento organizzativo, ad esempio tramite interventi mirati su informazione, conferimento e ottimizzazione dei percorsi di raccolta.
In aggiunta, per rendere l'analisi più operativa, si potrebbe costruire un semplice indice sintetico di difficoltà strutturale, combinando le variabili di contesto con segno coerente (ad esempio maggiore digital divide e maggiore dispersione territoriale → maggiore difficoltà). Tale indice consentirebbe di produrre una classifica dei comuni più "in difficoltà" e di rappresentare i risultati su una mappa, (indicando magari i 10 comuni più in difficoltà) facilitando l'individuazione delle aree critiche e il confronto tra criticità strutturali e performance osservata.

In conclusione il lavoro intende proporre un quadro analitico solido e coerente da cui partire. I risultati ottenuti mostrano come l'interpretazione della raccolta differenziata richieda strumenti statistici robusti e una lettura attenta del contesto territoriale. Gli sviluppi suggeriti aprono la strada a future analisi più approfondite, capaci di affiancare alla spiegazione statistica una comprensione sempre più fine delle determinanti reali del fenomeno.

FINE REPORT - 2052 parole

APPENDICE

- Script R-

```
install.packages("readxl")

#avvio i pacchetti che mi servono
library(readxl)
library(corrplot)
library(ggplot2)
library(scales)
library(boot)
library(leaps)
library(correlation)
library(tidyverse)
library(forcats)
library(broom)

#leggo i dati dal foglio excel in questione
dati <- read_excel("C:\\Users\\Jody\\Desktop\\emilia_romagna_report.xlsx")
View(dati)
head(dati, 10)

#RIMOZIONE CELLE VUOTE
dim(dati)
dati <- na.omit(dati)
dim(dati)

names(dati)
```

```
#pulizia variaibli categoriche e con anno sbagliato

#Sono state eliminate le variabili categoriche e identificative e rimosse le misure

#di superficie ridondanti o puramente dimensionali, mantenendo solo quelle più interpretabili e

#informative ai fini del modello di regressione.

dati_num2 <- dati[ , -c(1, 2, 3, 4, 8, 11, 13, 14, 15, 20)]

names(dati_num2)

dim(dati_num2)



names(dati_num2)



#statistiche sul dataset

summary(dati_num2)



#grafici per data vis -> PRESENTAZIONE INIZIALE REPORT!!!



#Istogrammi frequenza-differenziata

ggplot(dati, aes(x = Differenziata_2022)) +

  geom_histogram(bins = 25, fill="#81c784", color="white", alpha=.8) +

  geom_density(color="#1b5e20", linewidth=1.2) +

  theme_minimal(base_size = 13) +

  labs(title="Distribuzione della raccolta differenziata (2022)",

       x="Raccolta differenziata (%)",

       y="Frequenza")


#Boxplot provinciale
```

```
ggplot(dati, aes(x = Provincia, y = Differenziata_2022)) +
  geom_boxplot(fill="#90caf9") +
  theme_minimal() +
  labs(title="Distribuzione della raccolta differenziata per provincia")
```

```
#Grafico a barre: Media della RD per provincia
dati %>%
  group_by(Provincia) %>%
  summarise(media_RD = mean(Differenziata_2022)) %>%
  ggplot(aes(x = reorder(Provincia, -media_RD), y = media_RD)) +
  geom_col(fill="#4fc3f7") +
  geom_text(aes(label=sprintf("%.1f%%", media_RD*100)),
            vjust=-0.3, size=3.5) +
  theme_minimal(base_size = 13) +
  labs(title = "Media della raccolta differenziata per provincia",
       x = "Provincia", y = "Media RD (%)")
```

```
#grafico correlazioni dopo aver tolto le colonne categoriche
cor(dati_num2)
cor <- cor(dati_num2)
corrplot(cor, type = "upper", tl.col = "black", tl.srt = 45 )
#correlazione positive -> Partecipazione_elettorale 0.41168671 /// REDDITO 0.30404106
#correlazione negative -> supforestale  -0.73811788  ///  digitdivide -0.60955601  ///  auto1000ab  -0.44145803
```

```
set.seed(1)

train <- sample(nrow(dati_num2), 262)



dati_train <- dati_num2[train, ]

dati_test  <- dati_num2[-train, ]




#REGRESSIONE LINEARE con tutte le variabili dentro che chiamo con estensione "TT"

lm.fit_tt <- lm(Differenziata_2022 ~ ., data = dati_train)

summary(lm.fit_tt)

pred_test <- predict(lm.fit_tt, newdata = dati_test)

mean((dati_test$Differenziata_2022 - pred_test)^2)

#Multiple R-squared:  0.6137,   Adjusted R-squared:  0.5935

#MSE -> 0.01087973

#variabili significative (3 e 2 stelline) -> AUTO1000  - SUPFORESTALE - DIGITDIVIDE



##Creiamo una variabile "digi" --> usando un ciclo if

#SERVE PER SMISTARE I COMUNI DICHIARATI CON UN PROBLEMA COL DIGIT_DIVIDE

dati$digi <- ifelse(dati$Digitaldivide_2011 >= 30, "not digital", "digital")



#GRAFICO CHE CI DICE CHE I COMUNI NON DIGITALI SONO LA MINORANZA QUASI AL 30%

# prepariamo i dati con percentuali

dati_pie <- dati %>%

  count(digi) %>%

  mutate(

    perc = n / sum(n),

    label = percent(perc, accuracy = 1)

  )


ggplot(dati_pie, aes(x = 2, y = n, fill = digi)) +

  geom_col(width = 1, color = "white", linewidth = 0.8) +

  coord_polar(theta = "y") +

  xlim(0.5, 2.5) +   # crea il "buco" centrale (donut soft)

  geom_text(
```

```
  aes(label = label),
  position = position_stack(vjust = 0.5),
  size = 6,       # <<< PERCENTUALI PIÙ GRANDI
  color = "white",
  fontface = "bold"
 ) +
 scale_fill_manual(
  values = c(
   "digital" = "#66bb6a",
   "not digital" = "#ef5350"
  ),
  labels = c("Digital", "Digital divide elevato")
 ) +
 labs(
  title = "Comuni per livello di digitalizzazione",
  subtitle = "I comuni con digital divide elevato rappresentano il 28%",
  fill = ""
 ) +
 theme_void() +
 theme(
  plot.title = element_text(
   hjust = 0.5,
   face = "bold",
   size = 16
  ),
  plot.subtitle = element_text(
   hjust = 0.5,
   size = 11,
   color = "grey40"
  ),
  legend.position = "right",
  legend.text = element_text(size = 11)
 )


#data visualisation in seguito a modello full che registra come variabili a 3stelle proprio le correlate positive
ggplot(
 dati,
 aes(
```

```
    x = Supforestale_2020,
    y = Differenziata_2022,
    color = Auto1000ab_2016
  )
) +
  geom_point(alpha = .7, size = 2.4) +
  geom_smooth(se = FALSE, linewidth = 1) +
  facet_wrap(~ digi) +
  scale_color_gradientn(
    colours = rev(c("darkred", "orange", "yellow", "green")),
    name = "Auto per 1000 ab."
  ) +
  labs(
    title = "Relazione tra Superficie Forestale e Raccolta Differenziata",
    subtitle = "Distinti per digital divide",
    x = "Superficie forestale",
    y = "Raccolta differenziata 2022",
    caption = "Fonte: dataset Emilia-Romagna"
  ) +
  theme_minimal(base_size = 13) +
  theme(
    plot.title = element_text(face = "bold", size = 18),
    plot.subtitle = element_text(size = 12, margin = margin(b = 10)),
    strip.text = element_text(face = "bold"),
    legend.position = "right"
  )
```

```
# 1 PUNTO
### SUBSET ###
```

```
##BEST SUBSET METHOD
set.seed(5)

regfit.full <- regsubsets(Differenziata_2022 ~ ., dati_train, nvmax = 13 )
reg.summary <- summary(regfit.full)
reg.summary
names(reg.summary)

reg.summary$adjr2

##Visualizziamo i risultati adj_R**2
par(mfrow = c(2, 2))
plot(reg.summary$rss , xlab = "Number of Variables", ylab = "RSS", type = "l")
plot(reg.summary$adjr2 , xlab = "Number of Variables", ylab = "Adjusted RSq", type = "l")
which.max(reg.summary$adjr2)
points(8, reg.summary$adjr2[8], col = "red", cex = 2, pch = 20)

##facciamo la stessa cosa anche con Cp e BIC
plot(reg.summary$cp, xlab = "Number of Variables", ylab = "Cp", type = "l")
which.min(reg.summary$cp)
points(7, reg.summary$cp[7], col = "red", cex = 2, pch = 20)
which.min(reg.summary$bic)
plot(reg.summary$bic , xlab = "Number of Variables", ylab = "BIC", type = "l")
points(5, reg.summary$bic[5], col = "red", cex = 2,  pch = 20)

#veidamo quali sono le variabili prese in considerazione
dev.off()
plot(regfit.full , scale = "r2")
plot(regfit.full , scale = "adjr2")
plot(regfit.full , scale = "Cp")
plot(regfit.full , scale = "bic")

#PROVIAMO I 2 MODELLI SEGUENDO LE INFO CHE CI DA ADJ-R**2 E BIC

#adj R**2
```

```
coef(regfit.full ,8)

#bic
coef(regfit.full ,5)
```

```
#REG LINEARE best_subset_ADJ-R**2
best.model_full_adj <- lm(Differenziata_2022 ~ CO2eq_2016 +
                Auto1000ab_2016 +
                `Stazioni ferroviarie_2021` +
                Digitaldivide_2011 +
                Reddito_2020 +
                Spesacomunale_2017 +
                Supforestale_2020 +
                Superficieagricola_2022, data = dati_train)
summary(best.model_full_adj)
pred_test <- predict(best.model_full_adj, newdata = dati_test)
mean((dati_test$Differenziata_2022 - pred_test)^2)
#Multiple R-squared:  0.6124,   Adjusted R-squared:  0.6002
#MSE -> 0.01107656
```

```
#REG LINEARE best_subset_BIC
best.model_full_bic <- lm(Differenziata_2022 ~ Supforestale_2020 +
                `Stazioni ferroviarie_2021` +
                Reddito_2020 +
                Digitaldivide_2011 +
                Auto1000ab_2016, data = dati_train)
summary(best.model_full_bic)
pred_test <- predict(best.model_full_bic, newdata = dati_test)
mean((dati_test$Differenziata_2022 - pred_test)^2)
#Multiple R-squared:  0.5991,   Adjusted R-squared:  0.5913
#MSE ->  0.01068958
```

```
##FORWARD E BACKWARD STEPWISE SELECTION

#foreward lo chiamerò così -> fwd

regfit.fwd <- regsubsets(Differenziata_2022 ~ ., data = dati_train, nvmax = 13, method = "forward")
summary(regfit.fwd)
reg_fwd.summary <- summary(regfit.fwd)
reg_fwd.summary


par(mfrow = c(2, 2))
plot(reg_fwd.summary$rss , xlab = "Number of Variables", ylab = "RSS", type = "l")
plot(reg_fwd.summary$adjr2 , xlab = "Number of Variables", ylab = "Adjusted RSq", type = "l")

which.max(reg_fwd.summary$adjr2)

points(8, reg_fwd.summary$adjr2[8], col = "red", cex = 2, pch = 20)


plot(reg_fwd.summary$cp, xlab = "Number of Variables", ylab = "Cp", type = "l")
which.min(reg_fwd.summary$cp)
points(7, reg_fwd.summary$cp[7], col = "red", cex = 2, pch = 20)
which.min(reg_fwd.summary$bic)
plot(reg_fwd.summary$bic , xlab = "Number of Variables", ylab = "BIC", type = "l")
points(5, reg_fwd.summary$bic[5], col = "red", cex = 2,  pch = 20)


dev.off()
plot(regfit.fwd , scale = "r2")
plot(regfit.fwd , scale = "adjr2")
plot(regfit.fwd , scale = "Cp")
plot(regfit.fwd , scale = "bic")
```

```
coef(regfit.fwd ,8)

coef(regfit.fwd ,5)




# fwd adjR**2 = best_sub_adjR**2

#fwd_bic = best_sub_bic !!!!


#BWD

regfit.bwd <- regsubsets(Differenziata_2022 ~ ., data = dati_train, nvmax = 13, method = "backward")

summary(regfit.bwd)

reg_bwd.summary <- summary(regfit.bwd)

reg_bwd.summary


par(mfrow = c(2, 2))

plot(reg_bwd.summary$rss , xlab = "Number of Variables", ylab = "RSS", type = "l")

plot(reg_bwd.summary$adjr2 , xlab = "Number of Variables", ylab = "Adjusted RSq", type = "l")

which.max(reg_bwd.summary$adjr2)

points(8, reg_bwd.summary$adjr2[8], col = "red", cex = 2, pch = 20)


plot(reg_bwd.summary$cp, xlab = "Number of Variables", ylab = "Cp", type = "l")

which.min(reg_bwd.summary$cp)

points(7, reg_bwd.summary$cp[7], col = "red", cex = 2, pch = 20)

which.min(reg_bwd.summary$bic)
```

```
plot(reg_bwd.summary$bic , xlab = "Number of Variables", ylab = "BIC", type = "l")

points(5, reg_bwd.summary$bic[5], col = "red", cex = 2,  pch = 20)




dev.off()

plot(regfit.bwd , scale = "r2")

plot(regfit.bwd , scale = "adjr2")

plot(regfit.bwd , scale = "Cp")

plot(regfit.bwd , scale = "bic")



coef(regfit.bwd ,8)

coef(regfit.bwd ,5)



# bwd_adjR**2 = best_sub_adjR**2

#bwd_bic = best_sub_bic !!!!



#RICAPITOLANDO ABBIAMO QUESTI 3 MODELLI A CONFRONTO



# - 1

#REGRESSIONE LINEARE con tutte le variabili dentro

lm.fit_tt <- lm(Differenziata_2022 ~ ., data = dati_train)

summary(lm.fit_tt)

pred_test <- predict(lm.fit_tt, newdata = dati_test)

mean((dati_test$Differenziata_2022 - pred_test)^2)

#Multiple R-squared:  0.6137,   Adjusted R-squared:  0.5935

#MSE -> 0.01087973
```

```
# - 2

#REG LINEARE best_subset_ADJ-R**2

best.model_full_adj <- lm(Differenziata_2022 ~ CO2eq_2016 +

                    Auto1000ab_2016 +

                    `Stazioni ferroviarie_2021` +

                    Digitaldivide_2011 +

                    Reddito_2020 +

                    Spesacomunale_2017 +

                    Supforestale_2020 +

                    Superficieagricola_2022, data = dati_train)

summary(best.model_full_adj)

pred_test <- predict(best.model_full_adj, newdata = dati_test)

mean((dati_test$Differenziata_2022 - pred_test)^2)

#Multiple R-squared:  0.6124,   Adjusted R-squared:  0.6002

#MSE -> 0.01107656



# - 3

#REG LINEARE best_subset_BIC

best.model_full_bic <- lm(Differenziata_2022 ~ Supforestale_2020 +

                    `Stazioni ferroviarie_2021` +

                    Reddito_2020 +

                    Digitaldivide_2011 +

                    Auto1000ab_2016, data = dati_train)

summary(best.model_full_bic)

pred_test <- predict(best.model_full_bic, newdata = dati_test)

mean((dati_test$Differenziata_2022 - pred_test)^2)

#Multiple R-squared:  0.5991,   Adjusted R-squared:  0.5913

#MSE ->  0.01068958
```

```
AIC(lm.fit_tt, best.model_full_adj, best.model_full_bic)

BIC(lm.fit_tt, best.model_full_adj, best.model_full_bic)
```

#RISULTATI

1 - modello "tutte variabili"

#AIC -> -352.1563

#BIC -> -298.6311

#Multiple R-squared: 0.6137,   Adjusted R-squared: 0.5935

#MSE -> 0.01087973

2 - modello "best_subset ADJ-R**2"

#AIC -> -361.2610

#BIC -> -325.5776

#Multiple R-squared: 0.6124,   Adjusted R-squared: 0.6002

#MSE -> 0.01107656

3 - modello "best_subset BIC"

#AIC -> -358.4432

#BIC -> -333.4648

#ultiple R-squared: 0.5991,   Adjusted R-squared: 0.5913

#MSE -> 0.01068958

--- SOLO 3 MODELLI (tabella aggiornata) ---

```
results <- tibble::tribble(
  ~Modello,                ~R2,    ~Adj_R2, ~MSE,       ~AIC,       ~BIC,
  "Tutte le variabili",        0.6137,  0.5935, 0.01087973, -352.1563,  -298.6311,
  "Best subset (Adj-R²)",      0.6124,  0.6002, 0.01107656, -361.2610,  -325.5776,
  "Best subset (BIC)",         0.5991,  0.5913, 0.01068958, -358.4432,  -333.4648
)

# 1) formato lungo (solo da results)
long <- results %>%
  pivot_longer(
    cols = c(R2, Adj_R2, MSE, AIC, BIC),
    names_to = "Metrica",
    values_to = "Valore"
  )

# 2) normalizzo e inverto dove serve (MSE/AIC/BIC: più basso = meglio)
long2 <- long %>%
  group_by(Metrica) %>%
  mutate(
    norm  = (Valore - min(Valore)) / (max(Valore) - min(Valore)),
    score = if_else(Metrica %in% c("MSE", "AIC", "BIC"), 1 - norm, norm)
  ) %>%
  ungroup()

# 3) ordine modelli = quello della tabella, ma al contrario (come avevi tu)
ordine_modelli <- rev(results$Modello)

# 4) ordine metriche
ordine_metriche <- c("Adj_R2", "R2", "MSE", "AIC", "BIC")

long2 <- long2 %>%
  mutate(
    Modello = factor(Modello, levels = ordine_modelli),
    Metrica = factor(Metrica, levels = ordine_metriche)
  )

# 5) plot
ggplot(long2, aes(x = Metrica, y = Modello, fill = score)) +
  geom_tile(color = "white", linewidth = 0.7) +
```

```
 geom_text(
  data = subset(long2, round(score, 2) != 1),
  aes(label = sprintf("%.2f", score)),
  size = 4,
  color = "black"
 ) +
 geom_text(
  data = subset(long2, round(score, 2) == 1),
  aes(label = sprintf("%.2f", score)),
  size = 6,
  fontface = "bold",
  color = "white"
 ) +
 labs(
  title = "Confronto modelli (score normalizzato 0–1)",
  subtitle = "1.00 = migliore performance per metrica (MSE/AIC/BIC invertiti)",
  x = "",
  y = ""
 ) +
 theme_minimal(base_size = 13) +
 theme(
  panel.grid = element_blank(),
  axis.text.x = element_text(face = "bold", size = 11),
  axis.text.y = element_text(face = "bold", size = 11),
  plot.title = element_text(face = "bold", size = 15),
  plot.subtitle = element_text(size = 11, color = "grey35")
 )
```

#REG LINEARE best_subset_ADJ-R**2 è il modello che spiega meglio con un Adjusted R-squared: 0.6002

#VARIABILI SIGNIFICATIVE -> auto 3s - digitdivide 2s - reddito 2s - supforestale 3s

#REG LINEARE best_subset_BIC è il modello che predice meglio con un MSE: 0.01068958

#VARIABILI SIGNIFICATIVE -> auto 3s - stazioni_ferroviarie 3s - digitdivide 2s - reddito 2s - supforestale 3s

#punto 2 -> RICAMPIONAMENTO modello che scegliamo per spiegare

#LOOCV best_subset_adj_R**2

```
set.seed(2)

lm.fit_loocv <- glm(Differenziata_2022 ~ CO2eq_2016 +
            Auto1000ab_2016 +
            `Stazioni ferroviarie_2021` +
            Spesacomunale_2017 +
            Digitaldivide_2011 +
            Reddito_2020 +
            Supforestale_2020 +
            Superficieagricola_2022, data = dati_train)
coef(lm.fit_loocv)

cv.err <- cv.glm(dati_train, lm.fit_loocv)

cv.err$delta
```

#dopo LOOCV -> 0.01502180 // MSE prima -> 0.01107656 -> PREDIZIONE ROBUSTA

```
#BOOTSTRAP -> controllo coefficienti



# 0) Formula del modello finale (UNA VOLTA SOLA)
form_finale <- Differenziata_2022 ~ CO2eq_2016 +
  Auto1000ab_2016 +
  `Stazioni ferroviarie_2021` +
  Spesacomunale_2017 +
  Digitaldivide_2011 +
  Reddito_2020 +
  Supforestale_2020 +
  Superficieagricola_2022

# 1) Funzione bootstrap (CORRETTA: prima ricampiona le righe, poi stima)
boot.fn <- function(data, index) {
  data_boot <- data[index, ]            # ricampionamento con rimpiazzo
  mod <- lm(form_finale, data = data_boot)   # fit sul campione bootstrap
  coef(mod)
}

# 2) Bootstrap sul training set (coerente con la tua validazione)
set.seed(100)
boot_res <- boot(data = dati_train, statistic = boot.fn, R = 2000)

# 3) Nomi coefficienti nell'ordine corretto
coef_names <- names(boot_res$t0)

# 4) CI percentile 95% per ogni coefficiente
get_ci_perc <- function(i) {
  ci <- boot.ci(boot_res, type = "perc", index = i)
  c(lower = ci$percent[4], upper = ci$percent[5])
}
ci_mat <- t(sapply(seq_along(coef_names), get_ci_perc))

# 5) Tabella completa bootstrap
tab_boot <- data.frame(
  Coeff    = coef_names,
  Original = as.numeric(boot_res$t0),
```

```
  SE_boot  = apply(boot_res$t, 2, sd),
  CI_low   = ci_mat[, "lower"],
  CI_high  = ci_mat[, "upper"]
) %>%
  mutate(
    includes_0 = (CI_low <= 0 & CI_high >= 0),
    robust_txt = ifelse(includes_0, "NO (include 0)", "YES (exclude 0)")
  )

tab_boot

# 6) Tabella pulita da report (SOLO 8 variabili, NO intercetta)
tab_clean <- tab_boot %>%
  filter(Coeff != "(Intercept)") %>%
  mutate(
    Beta   = Original,
    CI95   = paste0("[", signif(CI_low, 3), ", ", signif(CI_high, 3), "]"),
    Robust = ifelse(includes_0, "NO", "YES"),
    Segno  = ifelse(Beta > 0, "+", "-")
  ) %>%
  select(Variabile = Coeff, Segno, Beta, SE_boot, CI95, Robust) %>%
  mutate(across(c(Beta, SE_boot), ~ signif(.x, 4))) %>%
  arrange(desc(Robust), desc(abs(Beta)))

tab_clean

# 7) Forest plot (coef + CI 95% bootstrap) SOLO 8 variabili
tab_plot <- tab_boot %>%
  filter(Coeff != "(Intercept)") %>%
  mutate(
    Beta = Original,
    Robust = ifelse(includes_0, "NO", "YES"),
    Robust_ord = ifelse(Robust == "YES", 1, 0),
    lab = sprintf("%+.3g", Beta),

    # posizionamento etichette in base al segno
    hjust_lab = ifelse(Beta >= 0, 0, 1),
    nudge_lab = ifelse(Beta >= 0, 0.03, -0.03)
  ) %>%
```

```
  arrange(desc(Robust_ord), desc(abs(Beta))) %>%
  mutate(Coeff = factor(Coeff, levels = rev(Coeff)))

ggplot(tab_plot,
       aes(x = Beta, y = Coeff, xmin = CI_low, xmax = CI_high, color = Robust)) +
  geom_point(size = 2) +
  geom_errorbarh(height = 0.25) +
  geom_vline(xintercept = 0, linetype = "dashed") +
  geom_text(
    data = tab_plot,
    aes(x = Beta + nudge_lab, label = lab, hjust = hjust_lab),
    size = 4,
    show.legend = FALSE
  ) +
  labs(
    title = "Coefficienti del modello finale con IC 95% bootstrap",
    subtitle = "Robustezza: IC bootstrap 95% esclude lo zero",
    x = "Coefficiente stimato",
    y = ""
  ) +
  theme_minimal(base_size = 13)
```

#VARIABILI SIGNIFICATIVE -> auto 3s - digitdivide 2s - reddito 2s - supforestale 3s

#fortemente robuste dopo la conferma bootstrap

#proviamo a migliorare la predizione del modello best_subset_BIC perche era il modello con MSE più basso.

```
ggplot(dati_train, aes(x = Auto1000ab_2016, y = Differenziata_2022)) + geom_point(alpha = .85, size = 1.8) + geom_smooth()

ggplot(dati_train, aes(x = `Stazioni ferroviarie_2021`, y = Differenziata_2022)) + geom_point(alpha = .85, size = 1.8) + geom_smooth(method = "lm")

ggplot(dati_train, aes(x = Digitaldivide_2011, y = Differenziata_2022)) + geom_point(alpha = .85, size = 1.8) + geom_smooth(method = "lm")

ggplot(dati_train, aes(x = Reddito_2020, y = Differenziata_2022)) + geom_point(alpha = .85, size = 1.8) + geom_smooth()

ggplot(dati_train, aes(x = Supforestale_2020, y = Differenziata_2022)) + geom_point(alpha = .85, size = 1.8) + geom_smooth(method = "lm")
```

```
#tentativi

best.model_full_bic_poly <- lm(Differenziata_2022 ~ poly(Supforestale_2020, 2) +
                    `Stazioni ferroviarie_2021` +
                    Reddito_2020 +
                    Digitaldivide_2011 +
                    Auto1000ab_2016, data = dati_train)

summary(best.model_full_bic_poly)

pred_test <- predict(best.model_full_bic_poly, newdata = dati_test)

mean((dati_test$Differenziata_2022 - pred_test)^2)

# mse -> 0.01064501
```

```
best.model_full_bic_poly2 <- lm(Differenziata_2022 ~ Supforestale_2020 +
                    poly(`Stazioni ferroviarie_2021`, 2) +
                    Reddito_2020 +
                    Digitaldivide_2011 +
                    Auto1000ab_2016, data = dati_train)

summary(best.model_full_bic_poly2)

pred_test <- predict(best.model_full_bic_poly2, newdata = dati_test)

mean((dati_test$Differenziata_2022 - pred_test)^2)

# mse -> 0.0106306
```

```
best.model_full_bic_poly3 <- lm(Differenziata_2022 ~ Supforestale_2020 +
                    `Stazioni ferroviarie_2021` +
                    poly(Reddito_2020, 2) +
                    Digitaldivide_2011 +
                    Auto1000ab_2016, data = dati_train)
summary(best.model_full_bic_poly3)
pred_test <- predict(best.model_full_bic_poly3, newdata = dati_test)
mean((dati_test$Differenziata_2022 - pred_test)^2)
# mse -> 0.0104967
```

```
best.model_full_bic_poly4 <- lm(Differenziata_2022 ~ Supforestale_2020 +
                    `Stazioni ferroviarie_2021` +
                    Reddito_2020 +
                    poly(Digitaldivide_2011, 2) +
                    Auto1000ab_2016, data = dati_train)
summary(best.model_full_bic_poly4)
pred_test <- predict(best.model_full_bic_poly4, newdata = dati_test)
mean((dati_test$Differenziata_2022 - pred_test)^2)
# mse -> 0.01078364 -> non migliora
```

```
best.model_full_bic_poly5 <- lm(Differenziata_2022 ~ Supforestale_2020 +
                    `Stazioni ferroviarie_2021` +
                    Reddito_2020 +
                    Digitaldivide_2011 +
                    poly(Auto1000ab_2016, 2), data = dati_train)
summary(best.model_full_bic_poly5)
pred_test <- predict(best.model_full_bic_poly5, newdata = dati_test)
```

```
mean((dati_test$Differenziata_2022 - pred_test)^2)
# mse -> 0.01081788-> non migliora
```

```
best.model_full_bic_poly6 <- lm(Differenziata_2022 ~ poly(Supforestale_2020, 2) +
                    `Stazioni ferroviarie_2021` +
                    poly(Reddito_2020, 2) +
                    Digitaldivide_2011 +
                    Auto1000ab_2016, data = dati_train)
summary(best.model_full_bic_poly6)
pred_test <- predict(best.model_full_bic_poly6, newdata = dati_test)
mean((dati_test$Differenziata_2022 - pred_test)^2)
# mse -> 0.01047458
```

```
best.model_full_bic_poly7 <- lm(Differenziata_2022 ~ poly(Supforestale_2020, 2) +
                    poly(`Stazioni ferroviarie_2021`,2) +
                    poly(Reddito_2020, 2) +
                    Digitaldivide_2011 +
                    Auto1000ab_2016, data = dati_train)
summary(best.model_full_bic_poly7)
pred_test <- predict(best.model_full_bic_poly7, newdata = dati_test)
mean((dati_test$Differenziata_2022 - pred_test)^2)
# mse ->  0.01045385
```

```
#verifica  con LOOCV del mdello best_subset_bic

lm.fit_loocv_bic <- glm(Differenziata_2022 ~ Supforestale_2020 +
                `Stazioni ferroviarie_2021` +
                Reddito_2020 +
```

```
                Digitaldivide_2011 +
                Auto1000ab_2016, data = dati_train)
coef(lm.fit_loocv_bic)

cv.err <- cv.glm(dati_train, lm.fit_loocv_bic)

cv.err$delta
#mse con LOOCV -> 0.01489617   -> prima era 0.01068958
```

```
#verifica  con LOOCV del mdello best.model_full_bic_poly7
lm.fit_loocv_bic_poly <- glm(Differenziata_2022 ~ poly(Supforestale_2020, 2) +
                poly(`Stazioni ferroviarie_2021`,2) +
                poly(Reddito_2020, 2) +
                Digitaldivide_2011 +
                Auto1000ab_2016, data = dati_train)
coef(lm.fit_loocv_bic_poly)

cv.err <- cv.glm(dati_train, lm.fit_loocv_bic_poly)

cv.err$delta
#mse con LOOCV -> 0.01528543  -> prima era 0.01068958
```

```
#verifica  con LOOCV del mdello best.model_full_bic_poly3
lm.fit_loocv_bic_poly2 <- glm(Differenziata_2022 ~ Supforestale_2020 +
                `Stazioni ferroviarie_2021`  +
                poly(Reddito_2020, 2) +
                Digitaldivide_2011 +
                Auto1000ab_2016, data = dati_train)
coef(lm.fit_loocv_bic_poly2)

cv.err <- cv.glm(dati_train, lm.fit_loocv_bic_poly2)
cv.err$delta
#mse con LOOCV -> 0.01506447  -> prima era 0.01068958
```

```
#Abbiamo testato estensioni polinomiali. Sebbene alcuni modelli riducano
#leggermente l'MSE sul test, la LOOCV aumenta, suggerendo che il guadagno non è robusto.
#Per questo si preferisce il modello lineare BIC
```

```
mse_comp <- tibble::tribble(
  ~Modello,              ~MSE_test,    ~MSE_LOOCV,
  "BIC lineare",          0.01068958,   0.01489617,
  "BIC poly (tutte 2°)",    0.01045385,   0.01528543,
  "BIC poly(solo Reddi 2°)", 0.01049670,   0.01506447
)

mse_comp

mse_long <- mse_comp %>%
  pivot_longer(cols = c(MSE_test, MSE_LOOCV),
               names_to = "Tipo",
               values_to = "MSE") %>%
  mutate(
    Tipo = recode(Tipo,
                  MSE_test = "MSE test",
                  MSE_LOOCV = "MSE LOOCV"),
    Tipo = factor(Tipo, levels = c("MSE test", "MSE LOOCV")),
    Modello = factor(Modello, levels = rev(mse_comp$Modello))
  )

ggplot(mse_long, aes(x = Modello, y = MSE, fill = Tipo)) +
  geom_col(position = position_dodge(width = 0.75), width = 0.65) +
  geom_text(
    aes(label = sprintf("%.5f", MSE)),
    position = position_dodge(width = 0.75),
    vjust = -0.4,
    size = 3.8
  ) +
```

```
  labs(
    title = "Confronto MSE: test vs LOOCV (modelli BIC)",
    subtitle = "Le polinomiali migliorano leggermente sul test set, ma peggiorano in LOOCV",
    x = "",
    y = "MSE",
    fill = ""
  ) +
  theme_minimal(base_size = 13) +
  theme(
    axis.text.x = element_text(face = "bold"),
    plot.title = element_text(face = "bold")
  )
```

```
pred_test <- predict(best.model_full_bic, newdata = dati_test)

df_pred <- data.frame(
  Osservato = dati_test$Differenziata_2022,
  Predetto  = pred_test
)

ggplot(df_pred, aes(x = Osservato, y = Predetto)) +
  geom_point(alpha = 0.7, size = 3, color = "#2C7FB8") +
  geom_abline(
    intercept = 0, slope = 1,
    linetype = "dashed",
    linewidth = 1,
    color = "black"
  ) +
  labs(
    title = "Valori osservati vs predetti – modello BIC",
    subtitle = paste0(
```

```
    "MSE test = ",
    round(mean((df_pred$Osservato - df_pred$Predetto)^2), 5)
  ),
  x = "Raccolta differenziata osservata (%)",
  y = "Raccolta differenziata predetta (%)"
) +
theme_minimal(base_size = 13)
```

PROMPT E UTILIZZO DI CHATGPT

ChatGPT è stato utilizzato come supporto per:

- **Creazione di grafici e visualizzazioni di supporto**
- **Supporto e controllo dei risultati**
- **Revisione e rifinitura del testo del report (chiarezza e ortografia)**